



REPORTE

Analizamos una serie de tiempo con datos históricos para ajustarla de forma óptima a un modelo Box-Jenkins ARIMA(p,d,q).

Consideramos la información histórica de temperaturas promedio por año para la ciudad de Nueva York en el período 1870 -2020. Determinamos mediante la gráfica de prueba de Dickey-Fuller el siguiente valor.

```
# Realizar la prueba Dickey-Fuller

# H0: La serie NO ES ESTACIONARIA
# Ha: La serie SÍ ES ESTACIONARIA


from statsmodels.tsa.stattools import adfuller

result = adfuller(df["Average"])
print("El valor p de la prueba de Dickey-Fuller es: ", result[1])

El valor p de la prueba de Dickey-Fuller es: 0.8417172538965355
```

Se obtiene pues, que no hay evidencia estadística para rechazar H0 (y por lo tanto decir que la serie es estacionaria).

Procedemos así, a aplicar tantas diferencias como sea necesario para alcanzar la estacionariedad, en este caso, basta una sola diferencia.




Conclusión: La serie transformada de diferencias sí es estacionaria.

Se busca, con esta información, obtener los parámetros óptimos mediante el índice de información de Akaike, para esto, comparamos 6 combinaciones diferentes de parámetros p , d y q en el modelo general $ARIMA(p, d, q)$. Los reportes completos se encuentran en el archivo de python, aquí mostraremos solo los datos con respecto al índice que nos interesa:

Model:	ARIMA(0, 1, 1)	Log Likelihood	-239.064
Date:	Sat, 08 Aug 2026	AIC	482.128
Model:	ARIMA(0, 1, 2)	Log Likelihood	-238.836
Date:	Sat, 08 Aug 2026	AIC	483.672
Model:	ARIMA(1, 1, 1)	Log Likelihood	-238.826
Date:	Sat, 08 Aug 2026	AIC	483.652
Model:	ARIMA(2, 1, 1)	Log Likelihood	-238.810
Date:	Sat, 08 Aug 2026	AIC	485.620
Model:	ARIMA(2, 1, 2)	Log Likelihood	-237.753
Date:	Sat, 08 Aug 2026	AIC	485.506
Model:	ARIMA(6, 1, 1)	Log Likelihood	-237.040
Date:	Sat, 08 Aug 2026	AIC	490.081

Obtenemos la gráfica que incluye a los datos de prueba, de entrenamiento, las predicciones puntuales y el intervalo para la base de prueba.



Para saber qué tan confiables estos pronósticos usamos los indicadores del error vistos en el curso.

```
import numpy as np

acumulador1 = 0
acumulador2 = 0

for contador in range(0,30):
    acumulador1 += (test.iloc[contador][1] - predicciones.iloc[contador][1])**2
    acumulador2 += np.abs((test.iloc[contador][1] - predicciones.iloc[contador][1]) / test.iloc[contador][1])

mse = acumulador1 / 101
rmse = np.round(np.sqrt(mse),2)
mape = np.round((acumulador2/101)*100,2)

print("RMSE:", rmse, "MAPE:", mape,"%")

RMSE: 0.69 MAPE: 0.57 %
```

De los resultados podemos apreciar información muy prometedora, ya que el error promedio relativo es incluso menor al 1%, y el rango de error, aunque en grados de temperatura pudiera no parecer tan pequeño sigue siendo una aproximación importante a tomar en cuenta.